人工智能系统课堂小测题目与解答

2026 年秋季上海创智学院 · 第 02–04 讲 · 教师用

共 11 题，满分 50 分，学生作答时间约 30 分钟。题目与当前学生试卷逐题对应，每题附参考答案、解析及评分要点。计算结果允许保留准确分数；同一算术错误不重复扣分。

第 1 题　反向模式的适用场景　2 分

题目

标量损失对大量参数求梯度时，反向模式自动微分的主要优势是（　　）

A．逐个扰动参数后，可用函数值变化近似各参数的梯度。

B．前向计算后，一次反向遍历即可得到损失对全部参数的梯度。

C．每增加一个待求导参数，都必须增加一次完整的反向遍历。

D．参数越多，一次反向传播所需的总计算量越少。

参考答案与解析

答案：**B**。

标量损失只有一个输出。完成前向计算后，反向模式从损失出发沿计算图反向传播梯度，一次反向遍历即可得到损失对全部参数的梯度，不需要为每个参数重新遍历一次。

A 描述的是数值差分。C 把反向模式误解为逐参数重复求导。D 也不成立：参数增多并不意味着一次反向传播的总计算量下降。

评分：选 B 得 2 分；错选、多选或未选不得分。

课件对应：02：第 12、14 页

第 2 题　反向求导需要前向数值　2 分

题目

反向自动微分通常需要保留部分前向中间结果，主要原因是（　　）

A．保留这些结果后，反向传播就不再需要执行任何计算。

B．所有前向中间结果都必须永久保留，供后续每轮训练使用。

C．保存的中间结果就是模型参数的最终梯度，可直接用于更新参数。

D．部分算子的局部导数依赖前向数值，反向计算时需要使用这些数值。

参考答案与解析

答案：**D**。

有些算子的局部导数依赖前向输入或输出的数值。例如 $z = u \times v$，对 u 的局部导数为 v，对 v 的局部导数为 u；反向计算需要这些前向数值。保存必要中间结果会占用存储，但便于反向阶段使用。

A 把保存数据误当成免除计算；B 中“所有”“永久保留”不成立；C 混淆了前向中间结果与最终参数梯度。

评分：选 D 得 2 分；错选、多选或未选不得分。

课件对应：02：第 14、31 页

第 3 题　线程并行与 SIMD　2 分

题目

对独立的数组加法，如何合理结合多核 CPU 线程并行与 SIMD？（　　）

A．线程处理互不重叠的区间，线程内部使用 SIMD，并考虑小任务的调度成本。

B．使用多个线程时，线程内部改用标量运算，以免 SIMD 重复计算。

C．使用 SIMD 后，按向量宽度同比减少数组的读写字节数。

D．即使已接近内存带宽上限，也按线程数与 SIMD 宽度之积估算加速比。

参考答案与解析

答案：**A**。

多核线程并行把数组划分为互不重叠的区间，由不同线程处理；SIMD 在每个线程内部同时处理多个元素。两者作用于不同层次，可以组合使用。任务太小时，线程调度等开销可能抵消收益。

B 错在把两层并行理解为重复计算。C 错在把指令数量减少等同于读写字节数减少；相同的数组加法仍需读写相同元素。D 忽略内存带宽上限和调度开销，不能直接将两种并行度相乘作为加速比。

评分：选 A 得 2 分；错选、多选或未选不得分。

课件对应：03：第 8–9 页

第 4 题　CUDA 逻辑线程与物理资源　2 分

题目

关于 CUDA 逻辑线程与物理执行资源，下列说法正确的是（　　）

A．每个 thread 在整个 kernel 执行期间永久占用一个 CUDA core。

B．启动线程总数必须等于 GPU 的物理运算单元数量。

C．thread 有自身索引与状态，物理执行资源可以在不同时刻服务不同线程。

D．一个 warp 的每条指令都必然在一个时钟周期内完成。

参考答案与解析

答案：**C**。

CUDA thread 是具有自身索引和执行状态的逻辑执行实例。GPU 的物理执行资源在不同时刻执行不同线程的工作，逻辑线程数量不必等于物理运算单元数量。

A 错在认为线程永久独占一个 CUDA core；B 错在将启动线程数与物理资源数绑定。D 忽略指令的延迟、吞吐及执行依赖，一个 warp 的每条指令并不都能在一个时钟周期内完成。

评分：选 C 得 2 分；错选、多选或未选不得分。

课件对应：04：第 15–16 页

第 5 题　字节 stride 与转置视图　4 分

题目

A 是按行优先连续存储的 8×16 FP32 矩阵，每个元素占 4 B。T 是 A 的转置视图，共用原存储，不复制数据。stride 表示某维索引增加 1 时地址增加的字节数。

A 的（行 stride，列 stride）为（_____）B；T 的为（_____）B。

参考答案与解析

答案：**A 为 (64, 4) B；T 为 (4, 64) B**。

stride 表示某一维索引增加 1 时，地址增加多少字节。A 按行优先连续存储，每行含 16 个 FP32 元素，每个元素为 4 B。

A 的行 stride = 16×4 = 64 B；列 stride = 4 B。

转置视图满足 T[i,j] = A[j,i]，只交换行列含义，不改变原数据的物理顺序。因此 T 的行 stride 等于 A 的列 stride，T 的列 stride 等于 A 的行 stride。

注意：(16, 1) 和 (1, 16) 是以元素个数表示的 stride。本题要求字节数，还需要乘以每元素的 4 B。

评分：每个数值对 2 分，其中两个分量各 1 分；接受等价配对表示。

课件对应：03：第 13、16 页；04：第 69–70 页

第 6 题　串行比例与并行加速　4 分

题目

某固定工作量程序单核耗时 100 ms，其中 20 ms 必须串行，其余部分可理想均分到各核。忽略额外开销，4 核总耗时为 _____ ms，相对单核的加速比为 _____ 倍。

参考答案与解析

答案：**40 ms；2.5 倍（或 5/2 倍）**。

串行部分仍需 20 ms，只有其余的 80 ms 可以均分到 4 个核。

4 核时间 = 20 + 80/4 = 40 ms。

相对单核加速比 = 100/40 = 5/2 = 2.5。

不能直接把 100 ms 除以 4，否则把必须串行的部分也当成了可并行工作。

评分：每空 2 分。

课件对应：03：第 10 页

第 7 题　CPU cache 容量与块尺寸　4 分

题目

某 CPU cache 可供 A、B 两块数据使用的容量为 24 KiB。两块均为紧密存储的 8×256 FP32 数据（4 B/元素）。只考虑容量约束，两块需同时驻留；忽略冲突及其他开销，1 KiB = 1024 B。

A、B 合计占 _____ KiB；保持 A 不变、B 的列数仍为 256，则 B 最多可有 _____ 行。

参考答案与解析

答案：**16 KiB；16** 行。

先计算单块占用和每行占用，利用 256×4 B = 1024 B = 1 KiB 简化手算。

A 占用 = 8×256×4 B = 8 KiB；B 初始占用也为 8 KiB。

两块合计 = 8 + 8 = 16 KiB。

保持 A 不变，B 可用容量 = 24 − 8 = 16 KiB。

B 每行占 1 KiB，所以最多容纳 16/1 = 16 行。

题设的 24 KiB 已是可供 A、B 使用的容量，不需再扣除其他数据。这里仅检查容量是否足够，不讨论 cache 冲突或替换策略。

评分：每空 2 分。

课件对应：03：第 33–34 页

第 8 题　布局转换成本与复用收益　4 分

题目

同一输入需要串行重复计算 K 次（K 为正整数）。原方案每次耗时 2 ms；优化方案先进行一次数据重排，耗时 4 ms，此后每次计算耗时 1 ms，重排结果可重复使用。忽略其他开销。两方案总耗时相等时，K = _____；优化方案总耗时严格更短时，K 最小为 _____。

参考答案与解析

答案：**4；5**。

数据重排只执行一次，此后的 K 次计算串行进行，且共用重排结果。

原方案总时间 = 2K ms；优化方案总时间 = (4 + K) ms。

耗时相等：2K = 4 + K，得到 K = 4。

优化方案严格更短：4 + K < 2K，得到 K > 4。

K 是正整数，所以满足“严格更短”的最小值为 5。K = 4 只是盈亏平衡点，不能填入第二空。

评分：每空 2 分。

课件对应：03：第 17 页

第 9 题　Roofline 与优化选择　8 分

题目

某算子执行 24 GFLOP，DRAM 总读写量为 6 GB。硬件计算吞吐上限为 1200 GFLOP/s，DRAM 带宽上限为 200 GB/s。G 均表示 10^9。仅使用 Roofline 模型，忽略其他开销；计算的是理论边界，不是实测值。

（1）计算算术强度、性能上界及执行时间下界，判断瓶颈。（4 分）

（2）方案 A 仅将计算吞吐上限翻倍；方案 B 仅将 DRAM 总读写量减半。两方案分别相对原方案评估，计算工作量不变。分别求时间下界，并解释哪个方案改善了理论边界。（4 分）

参考答案与解析

答案：算术强度 4 FLOP/B，性能上界 800 GFLOP/s，时间下界 30 ms，受 DRAM 带宽限制。方案 A 为 30 ms；方案 B 为 20 ms，应选 B。

先分析原方案

算术强度 I = 24 GFLOP / 6 GB = 4 FLOP/B。

带宽对应的性能上界 = 200 GB/s × 4 FLOP/B = 800 GFLOP/s。

Roofline 性能上界 = min(1200, 800) = 800 GFLOP/s。

时间下界 = 24/800 s = 30 ms。

800 小于硬件计算吞吐上限 1200，因此原方案受 DRAM 带宽限制。也可直接分别计算计算时间与搬运时间，再取较大者。

方案	计算时间下界	搬运时间下界	总时间下界
原方案	24/1200 s = 20 ms	6/200 s = 30 ms	30 ms
A 计算上限翻倍	24/2400 s = 10 ms	6/200 s = 30 ms	30 ms
B 总读写量减半	24/1200 s = 20 ms	3/200 s = 15 ms	20 ms

为什么方案 B 有效

方案 A 没有缓解带宽瓶颈，因此理论时间下界不变。方案 B 将 DRAM 总读写量从 6 GB 降至 3 GB，算术强度变为 8 FLOP/B，性能上界达到 min(1200, 200×8) = 1200 GFLOP/s，转为计算限制。

两方案分别相对原方案评估，不叠加。以上都是理论边界，不能保证实测达到该时间或相同比例的加速。

评分：第（1）问四项各 1 分。第（2）问：A 时间 1 分；B 模型与时间各 1 分；选择 B 并说明原因 1 分。共 8 分。

课件对应：03：第 19、21 页

第 10 题　GPU 分块矩阵乘的访存量　8 分

题目

在 GPU 上用 CUDA 计算 C = A×B，三者均为 16×16 的 FP32 矩阵（4 B/元素），已位于 GPU 全局内存。每个输出在寄存器中累加，最后写回一次，不读旧 C。统计整个矩阵计算的全局内存读写请求字节数，同一地址的重复读取重复计数；不计缓存影响、事务粒度及 CPU–GPU 传输，1 KiB = 1024 B。

普通方案：每个输出独立读取所需的 16 对 A、B 元素。分块方案：每个线程块（block）负责 4×4 输出，沿内积维分 4 轮；每轮将一个 A 块和一个 B 块（均为 4×4）各加载一次到共享内存供块内复用，不同 block 分别加载。

（1）普通方案的输入读取量、输出写入量各是多少 KiB？（3 分）

（2）分块方案的输入读取量、总读写量各是多少 KiB？（3 分）

（3）分块方案的输入读取请求量是普通方案的几分之一？实际 DRAM 输入读取量是否必然同比减少？说明理由。（2 分）

参考答案与解析

答案：普通方案输入 32 KiB、输出 1 KiB；分块方案输入 8 KiB、总读写量 9 KiB。输入请求量变为 1/4，但实际 DRAM 输入读取量不一定同比减少。

普通方案逐输出计数

整个 C 有 16×16 = 256 个输出。每个输出独立读取 16 对 A、B 元素，即 32 个 FP32 元素。

输出写入量 = $16^2 \times 4$ B = 1 KiB。

输入读取量 = $16^2 \times 32 \times 4$ B = 32×1 KiB = 32 KiB。

分块方案逐线程块计数

block 数 = $(16/4)^2 = 16$。

每轮输入 = 2×4×4×4 B = 128 B；每 block 共 4 轮。

每 block 输入 = 4×128 B = 512 B = 1/2 KiB。

全部 block 输入 = 16×(1/2) KiB = 8 KiB。

总读写量 = 输入 8 KiB + 输出 1 KiB = 9 KiB。

这里统计整个矩阵的全局内存请求。同一地址被多个 block 读取时分别计数，不计共享内存访问或 CPU–GPU 传输。

请求减少不等于实际 DRAM 同比减少

输入读取请求之比 = 8/32 = 1/4。

两种方案的缓存命中与复用情况可能不同；实际传输还受事务粒度影响。因此，不能仅凭程序请求量之比断定 DRAM 输入读取量之比。不要把输入量之比与总读写量之比混用。

评分：第（1）问：输入模型与结果各 1 分，输出 1 分。第（2）问：输入模型与结果各 1 分，总读写量 1 分。第（3）问：1/4 得 1 分；答“不能”并给出有效理由得 1 分。共 8 分。

课件对应：04：第 101、103、110 页

第 11 题　双缓冲流水线排布　10 分

题目

依次处理 4 块数据，每块先搬运 2 ms，再计算 3 ms。只有一个搬运资源和一个计算资源，两者可并发，各自同时至多处理一块。数据块间无计算依赖。

使用两个缓冲区，初始均空，每个恰好容纳一块；每块从搬运开始到计算结束持续占用其缓冲区。所有输入在 t = 0 就绪，不计启动、同步开销及输出传输。

（1）在下表排出最短完成时间的流水线：用连续方格表示任务，标注搬运 L1–L4、计算 C1–C4；未使用的方格留空。（6 分）

时间/ms	0–1	1–2	2–3	3–4	4–5	5–6	6–7	7–8	8–9	9–10	10–11	11–12	12–13	13–14
搬运														
计算														

（2）逐块串行执行共需 _____ ms，流水执行最短需 _____ ms，

流水相对串行的加速比为 _____ 倍（可用分数）。（4 分）

参考答案与解析

答案：串行 20 ms；最短流水时间 14 ms；加速比 10/7。下表是一种最短排布。

时间/ms	0–1	1–2	2–3	3–4	4–5	5–6	6–7	7–8	8–9	9–10	10–11	11–12	12–13	13–14
搬运	L1	L1	L2	L2		L3	L3		L4	L4				
计算			C1	C1	C1	C2	C2	C2	C3	C3	C3	C4	C4	C4

L1–L4 分别表示各块的搬运，C1–C4 表示各块的计算。空白表示该资源空闲；同一任务的连续格子组成其执行区间。

为什么 L3 不能从 4 ms 开始

缓冲区 A 先供第 1 块使用，到 C1 在 5 ms 结束后才能给第 3 块；缓冲区 B 先供第 2 块使用，到 C2 在 8 ms 结束后才能给第 4 块。4 ms 时两个缓冲区都被占用，因此 L3 最早从 5 ms 开始。

串行时间 = 4×(2 + 3) = 20 ms。

流水时间至少为 首次搬运 2 ms + 4 次计算 × 3 ms = 14 ms。

上表的计算从 2 ms 连续进行至 14 ms，且满足双缓冲约束，因此达到下界。

加速比 = 20/14 = 10/7，无需化为小数。

评分：排布 6 分：任务时长和先搬后算 2 分，各资源内不重叠且能跨资源重叠 2 分，双缓冲复用合法 2 分。数值 4 分：20 ms 得 1 分，14 ms 得 2 分，10/7 得 1 分。接受其他最短合法排布。

课件对应：03：第 22–24 页